Contrato de dados, repositório e baseline

Entrega 4 — Aprendizagem de Máquina Supervisionada

UFPB · CCSA · Ciência de Dados para Negócios · 2026.2

Equipe F: Brenno Henrique Alves da Silva Costa; Gustavo Henrique Rocha Oliveira; Iasmin Vieira de Lima. **Data:** 22/10/2026.
Repositório: https://github.com/brennohdev/mls-2026.2-desabastecimento-sus

1. Contexto e objetivo

Após a escuta no HU-UFPB (Entrega 3), o recorte passou a ser a **previsão de demanda de antimicrobianos**. A farmácia controla, em planilha manual, os tratamentos ativos para garantir que nenhum paciente fique sem o medicamento no meio do tratamento. A decisão apoiada é **quanto de cada antimicrobiano reservar/repor para o próximo mês**. Esta entrega produz a base analítica, o diagnóstico de qualidade, a partição e o baseline.

2. Contrato de dados

Chave e unidade	Um **tratamento** de um paciente com um antimicrobiano (uma linha).
Granularidade	Tratamento; agregado para **princípio ativo** × **mês** na modelagem de demanda.
Cobertura	2025-03 a 2026-10; 7.425 tratamentos; 32 antimicrobianos; 17 setores.
Alvo	Demanda mensal (soma de `qtd_total`) por antimicrobiano; fonte: planilha de tratamento (AGHU).
Corte temporal	Fechamento do mês: prevê-se a demanda do mês seguinte.
Atualização	A planilha é atualizada ao menos uma vez por dia na origem.
Restrições	Dado operacional do hospital; nome do paciente já anonimizado; não redistribuível; uso acadêmico.

3. Relatório de qualidade

Principais problemas encontrados e decisões aplicadas (contagens antes/depois registradas no notebook):

Variável/base	Problema e decisão	Impacto
`qtd_resta`	99,8% ausente; sem informação útil. Removida.	Nenhuma perda de sinal.
`qtd_dispensada`	98,3% ausente. Removida.	Idem.
`suspender`	78,7% ausente; ausência significa "não suspenso". Convertida em flag binária.	Mantém o sinal sem imputar falso.
linhas duplicadas	164 linhas idênticas. Removidas.	Evita contagem dobrada de demanda.
`data_inicio` ausente	Poucas linhas sem data. Removidas (não entram na série).	Série temporal consistente.
mês 2026-10	Coleta em 22/10: mês incompleto (demanda cai artificialmente). Excluído da modelagem.	Evita viés na métrica.
`setor`	Variações de grafia (ex.: espaços). Normalizado (maiúsculas, espaços).	Categorias consistentes.

Observações: a demanda mensal total é estável (faixa de 12 a 18 mil unidades/mês). A situação dos tratamentos é 78% encerrada, 20% suspensa e 2% em andamento; a suspensão é um fenômeno frequente e candidato a alvo futuro (risco de interrupção).

4. Diagnóstico de vazamento

Corte: previsão no fechamento do mês para o mês seguinte. Classificação de variáveis:

Variável	Permitida?	Justificativa (relação com o corte)
`principio_ativo`	Sim	característica estável do item, conhecida antes do corte.
`setor`	Sim	definida na prescrição; existe antes do corte.
mês do ano (sazonalidade)	Sim	derivada da data de início; não usa o futuro.
lags de `qtd_total`	Sim	usa apenas meses anteriores já encerrados.
`data_termino`	Não	vazamento temporal: só conhecida após o fim do tratamento.
`situacao`	Não	vazamento de alvo: é o desfecho, só existe depois.
`qtd_dispensada`, `qtd_resta`	Não	consequência da decisão: registradas conforme o consumo ocorre.

Consequência da decisão. Variáveis como `situacao` e `qtd_dispensada` parecem ótimas preditoras, mas só existem porque o tratamento já aconteceu; em produção não estariam disponíveis no corte. Por isso são proibidas.

5. Partição e baseline

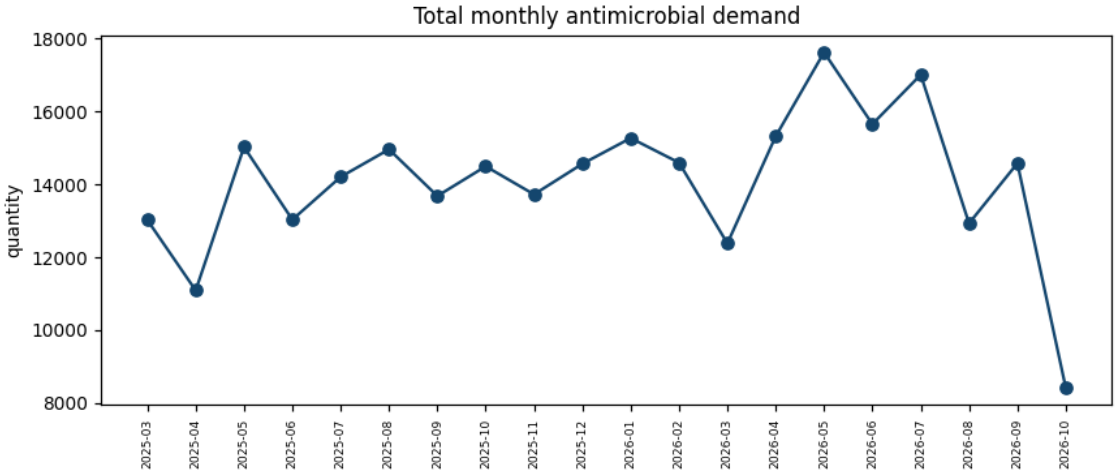
Estratégia: temporal. Como a decisão é aplicada ao futuro, o teste são os últimos meses, não um sorteio aleatório. *Cenário imitado:* "no fim de cada mês, prever a demanda do mês seguinte."

- Treino: 2025-03 a 2026-05 (15 meses). Teste: 2026-06 a 2026-09 (4 meses).
- Pré-processamento (quando o modelo entrar) será ajustado só no treino, dentro de `Pipeline`, aplicando `transform` a validação/teste.

Baselines (métrica no conjunto de teste):

Baseline	MAPE	MAE
Trivial (média do treino)	**9,6%**	1.478
Operacional (persistência: repor como no mês anterior)	15,8%	2.262

Métrica escolhida: MAPE (erro percentual de demanda), por ser interpretável para a farmácia e coerente com a decisão de reposição. **Número de referência do semestre: MAPE ≈ 9,6%**; a demanda é estável, então qualquer modelo precisa superar a média para justificar complexidade.



6. Reprodutibilidade e verificação individual

O notebook `notebooks/auditoria_baseline.ipynb` executa do início ao fim (via `make notebook` / `uv`), apoiado no pacote `huforecast` (camadas: ingestão, processamento, features, modelagem), sem edição manual nem caminhos absolutos. Os dados brutos não são versionados (ver `.gitignore` e `data/raw/README.md`).

Verificação individual (diagnóstico de 3 variáveis por integrante):

- **Brenno** — `principio_ativo` (permitida: estável, pré-corte); `data_termino` (proibida: vazamento temporal); `qtd_dispensada` (proibida: consequência da decisão).
- **Gustavo** — `setor` (permitida); `situacao` (proibida: alvo/desfecho); `qtd_resta` (proibida: consequên-

cia).

- **Iasmin** — mês do ano (permitida: sazonalidade sem futuro); `data_termino` (proibida: temporal); `situacao` (proibida: consequência).

Uso de IA generativa

Assistente de IA usado para apoio à auditoria dos dados, estruturação do pipeline (funções de limpeza, baseline) e redação. As decisões de limpeza, partição e métrica são da equipe. Nenhum dado pessoal de paciente foi inserido em serviço externo.