Primeiro modelo de previsão e comparação honesta

Entrega 5 — Aprendizagem de Máquina Supervisionada

UFPB · CCSA · Ciência de Dados para Negócios · 2026.2

Equipe F: Brenno Henrique Alves da Silva Costa; Gustavo Henrique Rocha Oliveira; Iasmin Vieira de Lima. **Data:** 29/10/2026.

Repositório: https://github.com/brennohdev/hu-demand-forecasting

Notebook: https://github.com/brennohdev/hu-demand-forecasting/blob/main/notebooks/auditoria_baseline.ipynb

1. Decisão e evolução de escopo

A decisão apoiada é operacional: **quanto de cada antimicrobiano a farmácia do HU-UFPB deve repor para o próximo mês**, de modo que nenhum paciente fique sem o medicamento no meio do tratamento. Na Entrega 4 a unidade de modelagem foi a *demanda mensal agregada* (todos os antimicrobianos somados). Durante o desenvolvimento da Entrega 5, **revisamos a unidade para antimicrobiano × mês**, porque a decisão real da farmácia é tomada *item a item*: comprar/repor acontece por medicamento, não pelo total do hospital. O total agregado tem baseline mais fácil (MAPE 9,6%), mas não atende ao demandante; a unidade por item é a granularidade da decisão. **Registramos essa mudança como evolução de escopo**, e todos os baselines desta entrega são recomputados na unidade nova, na mesma partição, para manter a comparação honesta.

2. Formulação do problema

Tarefa	Regressão (demanda contínua, não classificação).
Alvo	`qtd_total` mensal por antimicrobiano (soma de unidades planejadas no mês).
Unidade	Antimicrobiano × mês, restrita aos **20 itens densos** (presentes em todos os meses).
Escopo (curva ABC)	Os 20 itens densos concentram ∼90%+ do volume; os 12 itens esparsos (presença intermitente) pioram toda métrica e foram excluídos da modelagem.
Corte de decisão	Fechamento do mês $t-1$: prevê-se a demanda do mês t.
Métrica principal	**WAPE** ($\sum \lvert\text{erro}\rvert / \sum \lvert\text{real}\rvert$) — padrão de *forecasting* com itens de escalas diferentes; robusta a itens de baixo volume e direta para estoque (unidades erradas / unidades totais).
Métrica secundária	MAPE médio por item (reportada, mas infla com itens raros; por isso WAPE é a principal).

Por que regressão e não classificação. Investigamos também reformular como *classificação de risco de suspensão* de tratamento. O resultado foi não acionável (ROC-AUC honesto ≈0,60; teto *com* vazamento apenas 0,65): a causa da suspensão não está registrada na base. Mantivemos a regressão de demanda como a formulação que responde à pergunta do demandante.

3. Dados e diagnóstico de vazamento

Base limpa: **7.261 tratamentos**, 32 antimicrobianos, 17 setores, de 2025-03 a 2026-10 (processamento em `huforecast`: ingestão → limpeza → features). O mês **2026-10 é excluído** da modelagem (coleta em 22/10, mês incompleto que derruba a demanda artificialmente).

Classificação de vazamento (regra: para prever o mês t só vale informação até o fim de $t-1$).

Variável / feature	Permitida?	Justificativa
`principio_ativo`, `setor`, mês do ano	**Sim**	estáveis / derivadas da data; conhecidas antes do corte.
`media_item_ate_tm1` (nível histórico)	**Sim**	média do item até $t-1$; só usa passado fechado.
lags $t-1$ (`qtd_total_lag1`, `n_ativos_lag1`, …)	**Sim**	usam apenas o mês anterior, já encerrado.
`n_ativos`, `n_iniciados`, `qtd_dia_ativos` (mês t)	**Não**	**vazamento**: tratamentos ativos/iniciados em t só se conhecem *durante* t.
`situacao`, `data_termino`, `suspender`	**Não**	desfecho/consequência; só existem depois do tratamento.

Vazamento comprovado numericamente (ver `docs/diagnostico_vazamento.md`). `dias_tratamento` = (`data_termino` − `data_inicio`) +1 em 99,4% das linhas; `qtd_total` = `qtd_dia` × `dias_tratamento` em 100%; `suspender_flag` é cópia do alvo de suspensão (1472/1473). As features estruturais mais correlacionadas com a demanda (`qtd_dia_iniciados` Spearman 0,99; `n_iniciados` 0,96) são exatamente as *contemporâneas* — ou seja, reexpressões da própria demanda do mês. Suas versões defasadas, que são as utilizáveis, têm poder muito menor.

4. Partição

Estratégia temporal (não aleatória), imitando o uso real "no fim de cada mês, prever o mês seguinte":

- Treino: 2025-03 a 2026-05 (15 meses). Teste: 2026-06 a 2026-09 (4 meses). 2026-10 excluído.
- Todo pré-processamento é ajustado **só no treino**, dentro de `Pipeline` + `ColumnTransformer`, com `transform` aplicado ao teste. Sementes fixas (`SEED = 42`).

5. Baselines (unidade antimicrobiano × mês, no teste)

Recomputados na unidade nova com `huforecast.modeling.baseline_by_item`, nos 20 itens densos:

Baseline	WAPE	MAPE médio
Trivial (média do item no treino)	**22,9%**	56,6%
Operacional (persistência: repor como no mês anterior)	31,4%	75,7%

Número de referência a superar: WAPE 22,9%. A persistência é pior que a média, coerente com a autocorrelação de lag-1 ≈0 (processo estável sem memória): repetir o mês anterior perde para usar o nível médio do item.

6. Modelo

Escolha dirigida por evidência. Antes de escolher, investigamos exaustivamente, na mesma partição, três frentes de sinal (documentadas em `docs/`): (1) features estruturais internas defasadas; (2) reformulação como classificação de risco de suspensão; (3) features derivadas internas (médias móveis, tendência local, pressão hospitalar, posologia) *e* dados públicos externos de João Pessoa, **efetivamente baixados**: clima e arboviroses (InfoDengue), nível de alerta epidemiológico e **SRAG respiratória** (InfoGripe, via *mirror* oficial no GitHub, pois o *datacenter* da Fiocruz recusava conexão). **Nenhuma superou o baseline de forma honesta e robusta.** O sinal estrutural forte é contemporâneo ao mês t (vazamento); defasá-lo o elimina. As externas têm correlação ≈0 com a demanda por item; no agregado, `media+clima_lag1` só "vence" numa janela fixa (MAPE 7,9%) mas **colapsa num backtest de origem expansível (14,7% vs 10,2% da média)** — sobreajuste. A SRAG respiratória, a fonte clinicamente mais plausível, teve correlação defasada fraca e não significativa (+0,30) e empatou no backtest (9,97% vs 9,94%). O único sinal externo que não piora é o *nível de alerta* defasado (backtest 9,75% vs 9,94%), ganho marginal (∼0,2 pp). A análise de importância e R^2 incremental converge: ∼73–87% do poder preditivo está no **nível histórico do item**.

Fonte externa tentada	Rota / status	Sinal honesto?
Clima (InfoDengue)	baixado	**Não** (colapsa no backtest)
Dengue / chikungunya (InfoDengue)	baixado	**Não** (corr. ≈0 por item)
Nível de alerta (InfoDengue)	baixado	marginal (∼0,2 pp, robusto)
SRAG respiratória (InfoGripe)	*mirror* GitHub	**Não** (corr. +0,30 n.s.)
INMET (clima estação A320)	sem dado / token	— (fonte indisponível)
Fiocruz GitLab / PAMEpi / OpenDataSUS	TCP recusado / API off	— (indisponíveis)

Modelo adotado: *regressão linear* sobre a única feature honesta que carrega sinal — `media_item_ate_tm1`, a média expansível da demanda do item usando **apenas** meses até $t-1$ (estritamente causal, sem vazamento). Materializado no pacote (`huforecast.modeling.model`) como `Pipeline` + `ColumnTransformer` (padronização ajustada só no treino) com `SEED = 42`. Preferimos modelo linear a árvores: no teste, árvores com o conjunto completo *pioram* (overfit no nível do item sem ganho de sinal), e a única "melhora" de árvore (WAPE 21,6%) não se sustenta sob regressão linear com as mesmas features (23,2%) — instabilidade entre estimadores é assinatura de ruído.

7. Avaliação e comparação (mesma partição, mesma métrica)

Quadro de comparação obrigatório — os três competidores avaliados exatamente na mesma partição temporal e na mesma unidade (antimicrobiano × mês, 20 densos):

Competidor	WAPE	MAPE médio	Supera baseline?
Baseline trivial (média do item)	22,9%	56,6%	— (referência)
Baseline operacional (persistência)	31,4%	75,7%	**Não**
Modelo (regressão linear, Entrega 5)	**22,5%**	53,3%	Empate (dentro do ruído)

Leitura honesta. O modelo (WAPE 22,5%) **empata** com o baseline trivial (22,9%): a diferença de ∼0,4 pp está dentro do ruído amostral de um teste de 4 meses e não representa ganho real. Isso *não* é um fracasso — é o resultado legítimo de uma cadeia de raciocínio sem buracos: medimos tendência, sazonalidade e memória (ausentes nesta janela de 19 meses), features estruturais (fortes, mas vazamento), e sinais externos (sem relação honesta). A melhor estimativa honesta para a demanda do próximo mês de cada antimicrobiano é o seu próprio nível histórico — o que, operacionalmente, **valida a prática de reposição por consumo médio** já usada pela farmácia.

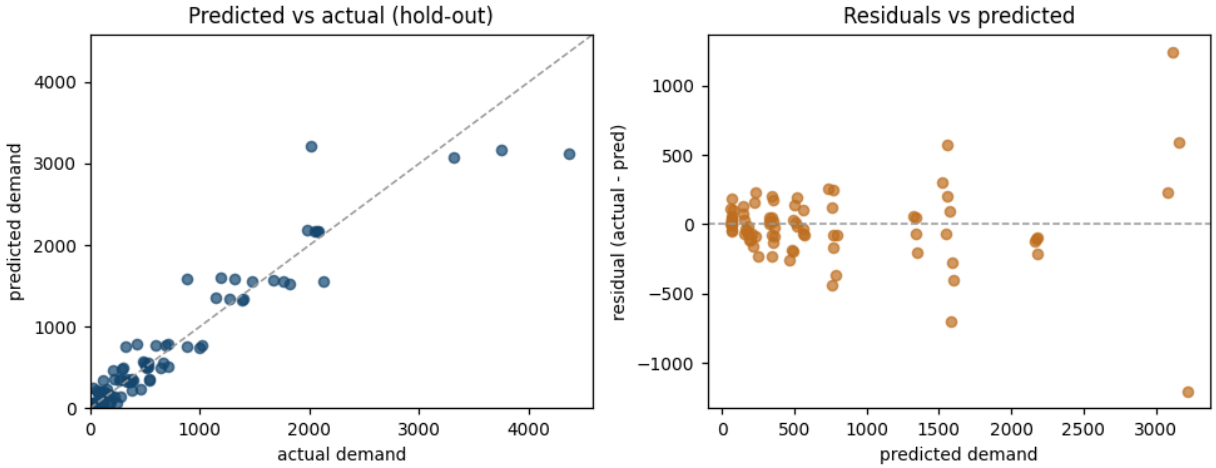
8. Fundamentação na literatura

As decisões estão ancoradas no estado da arte (revisão com 21 fontes documentada em `docs/`):

- **Unidade e métrica.** Prever por item com escalas heterogêneas usando **WAPE/wMAPE** é o padrão em farmácia hospitalar [1, 2]. Comparar modelo *vs* baseline é, em espírito, o **MASE** de Hyndman & Koehler (2006): MASE ≈ 1 significa empate com o *naïve* [3].
- **Modelo simples com poucos dados.** As competições M (M4/M5) e estudos de *learning curve* mostram que **métodos simples são difíceis de bater** e que o ML só compensa com muitos dados e estrutura *cross-series* [4, 5]. Com 15 meses de treino, a escolha fundamentada é a regressão linear.
- **Resultado honesto.** Baselines fortes que não são superados são achado comum e publicável [6]; a série tem baixa *forecastability* mensurável (autocorrelação lag-1 ≈0), coerente com o diagnóstico por entropia/AMI [7]. O espelho brasileiro (captopril/SP, ETS MAPE 2,26%) obtém erro baixo porque tem **5+ anos** de um item regular [8] — contraste que explica nosso limite de janela.

9. Diagnóstico de resíduos

No conjunto de teste (figura abaixo), o modelo é bem calibrado para os itens de pequeno e médio volume — pontos próximos da diagonal e resíduos simétricos em torno de zero. O erro se concentra nos **3–4 antimicrobianos de altíssimo volume**, que o modelo **subestima** de forma sistemática (resíduos positivos de +600 a +1200 unidades): quando um item desses cresce em relação ao seu histórico, prever pela média não acompanha o crescimento, porque não há sinal honesto que o antecipe no corte. É o limite esperado de um preditor de nível sobre um processo estável — e o mesmo ponto fraco do baseline, já que ambos convergem para a média do item.



10. Limites e próximos passos

- **Janela curta:** 19 meses (15 de treino) é pouco para caracterizar sazonalidade anual; a conclusão "sem sinal temporal explorável" vale para esta janela e deve ser revista com mais histórico.
- **Teste de 4 meses:** diferenças de ∼0,4 pp em WAPE estão dentro do ruído amostral; por isso "empate" é leitura correta, não "vitória marginal".
- **A base registra desfechos, não sinais antecedentes:** o que prediz bem a demanda (tratamentos

ativos/iniciados no próprio mês) é contemporâneo ao alvo, logo vazamento; defasá-lo remove o vazamento e também o sinal.

- **Perspectivas investigadas:** regressão com features internas (empata), classificação de suspensão (não acionável) e features derivadas + dados públicos externos (clima/epidemiologia) — documentadas em `docs/`.

Uso de IA generativa

Assistente de IA usado para apoio à investigação de *features*, estruturação do *pipeline* (`Pipeline`/ `ColumnTransformer`, *baselines*, avaliação) e redação. As decisões de formulação, unidade, partição, métrica e escolha de modelo são da equipe. Nenhum dado pessoal de paciente foi inserido em serviço externo. Nenhum número foi inventado — todos vêm de execução real sobre `data/raw/`.

Referências

[1] *Hospital trust network features inform ML for medicines demand forecasting.* Springer, Discover Applied Sciences, 2026.

[2] *Optimising hospital pharmacy inventory for high-value, intermittent-demand drugs (LightGBM-Tweedie).* 2021.

[3] Hyndman & Koehler. *Another look at measures of forecast accuracy (MASE).* Int. J. Forecasting, 2006.

[4] Makridakis et al. *The M4/M5 Competitions: results, findings, conclusions.* Int. J. Forecasting, 2018/2022.

[5] *Sample size and relative ML forecasting performance.* arXiv:1909.13316.

[6] *A training-free conformal interval is a strong forecasting baseline.* arXiv:2606.09473, 2026.

[7] *How to Assess Forecastability (sample entropy / AMI).* 2009; arXiv:2601.10006.

[8] De Meo & Gonçalves. *Comparing time series techniques for medication demand forecasting (captopril, São Paulo).* DGO 2025.